ICT이노베이션스퀘어 AI복합교육 고급 언어과정

자연어처리를 위한 RNN (Recurrent Neural Network)


현청천

2021.04.19

What is RNN

- 시계열(Sequential Data) 데이터를 처리하기 위한 모델
 - 음성, 언어, 주가, 센서 데이터 등







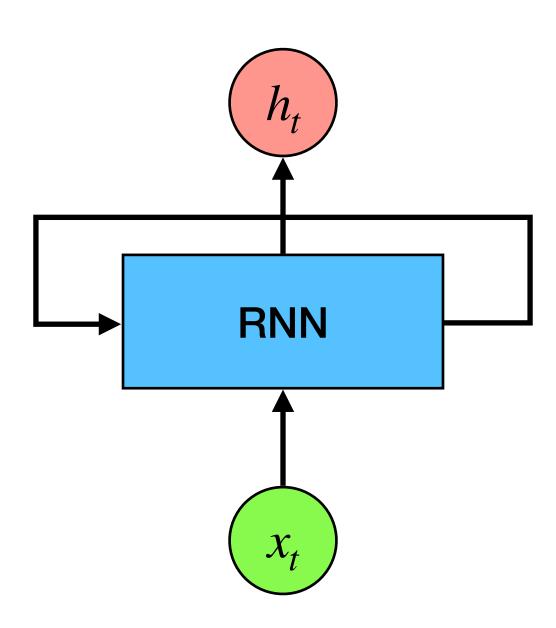
What is RNN

- 시계열(Sequential Data) 데이터를 처리하기 위한 모델
 - 음성, 언어, 주가, 센서 데이터 등
- 문장에서 이전에 나온 단어를 보가 다음단어를 예측




What is RNN

- 시계열(Sequential Data) 데이터를 처리하기 위한 모델
 - 음성, 언어, 주가, 센서 데이터 등
- 문장에서 이전에 나온 단어를 보가 다음단어를 예측
- 동일한 Weight와 Bias가 모든 입력 값에 대해서 동일하게 사용 됨



$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$




Sequencial Data

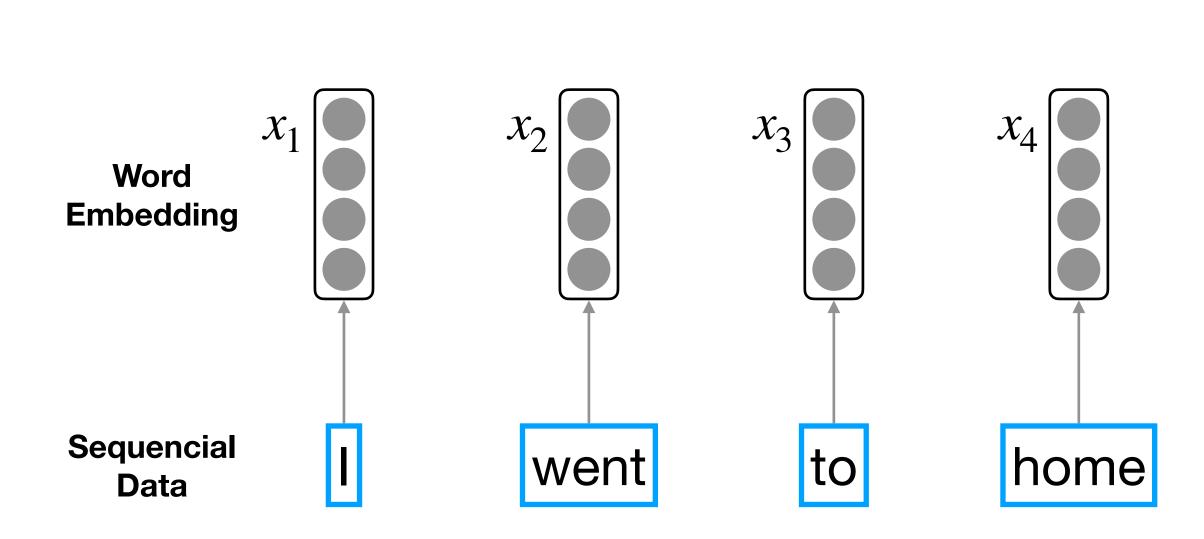
went

to


home


$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$







$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$






$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$







return_somenous = the




$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$




Total feature







문장의 특징 추출



간단한 표현




Word



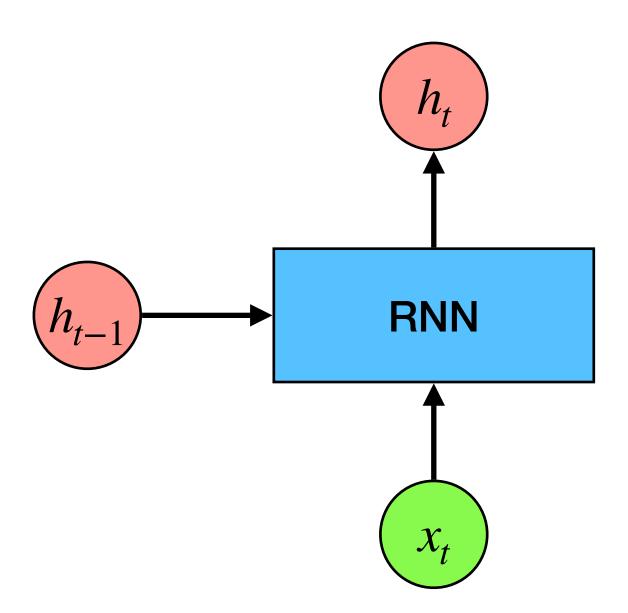
Multi layer stack

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem




RNN 네트워크를 재귀적으로 사용하므로 길이에 상관 없음

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem



h_t 를 계산하기 위해서는 h_{t-1} 이 필요해서 병렬처리 불가

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움

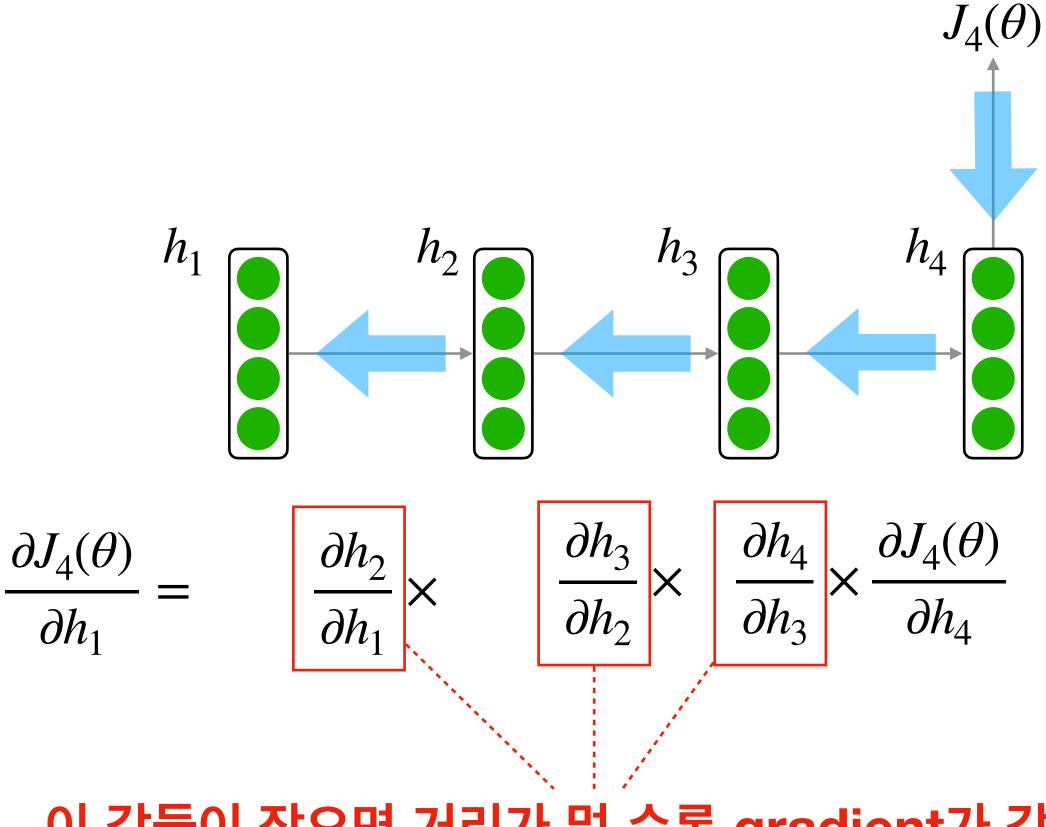


h_t 는최근 정보가 강하고 과거의 정보는 점차 약해짐

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

Chain rule!


$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



이 값들이 작으면 거리가 멀 수록 gradient가 감소함

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem


$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



먼 거리의 gradient는 사라지고 가까운 거리의 gradient만 영향을 받음

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem

$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$






20

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem


$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



이 값들이 크면 거리가 멀 수록 gradient가 증가함

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem


$$h_t = tanh(W_h h_{t-1} + W_x x_t + b)$$



학습이 잘 안되거나 Inf, NaN 등의 loss가 발생할 수 있음

22

- 길이에 상관이 없음
- 순서대로 처리해야 하므로 느림
- 오랜 과거의 정보를 접근하기 어려움
- Vanishing gradient problem
- Exploding gradient problem



Algorithm 1 Pseudo-code for norm clipping the gradients whenever they explode


$$\hat{\mathbf{g}} \leftarrow \frac{\partial \mathcal{E}}{\partial \theta}$$

if $\|\hat{\mathbf{g}}\| \geq threshold$ then

 $\hat{\mathbf{g}} \leftarrow \frac{threshold}{\|\hat{\mathbf{g}}\|} \hat{\mathbf{g}}$


end if

LSTM (Long-Short Term Memory)




What is LSTM

- RNN의 Vanishing gradient 문제를 해결하기 위한 모델
 - Memory cell을 추가 함 (long term state)
 - $c_t = c_{t-1} + function(h_{t-1}, x_t)$



LSTM (gates)

- Forget Gate: 이전 step Memory cell의 정보를 얼마나 사용할지 결정
- Input Gate: 새로 계산된 Memory cell을 얼마나 사용할지 결정




@2021 cchyun@gmail.com., Ltd All Rights Reserved.

4×12

LSTM (cell & hidden)

- New Cell Content: 현재 시점의 Memory cell 값
- Cell State: 과거 Cell State와 현재 시점의 Cell Content의 합
- Hidden State: 현재 시점의 출력 값



•
$$f_t = \sigma(W_{hf}h_{t-1} + W_{xf}x_t + b_f)$$

•
$$i_t = \sigma(W_{hi}h_{t-1} + W_{xi}x_t + b_i)$$


•
$$o_t = \sigma(W_{ho}h_{t-1} + W_{xo}x_t + b_o)$$

•
$$\tilde{C}_t = tanh(W_{hc}h_{t-1} + W_{xc}x_t + b_c)$$


•
$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

• $h_t = o_t \odot tanh(C_t)$

LSTM




GRU (Gated Recurrent Unit)




What is GRU

- LSTM보다 단순한 구조 이면서도 긴 데이터를 잘 처리함
 - Memory cell을 사용 안함
 - Gate 숫자를 2개로 줄임




GRU (gates)

- Reset Gate: 이전 시점 h_{t-1} 의 정보를 얼마나 사용할지 결정
- Update Gate: 현재 시점의 \tilde{h}_t 의 정보를 얼마나 사용할지 결정




GRU (hidden)

- New Hidden content: 현재 시점의 Hidden state 값
- Hidden state: 현재 시점의 출력 값



GRU



감사합니다.

